

Reconocimiento de Movimientos de Mano mediante Modelos Ocultos de Markov

JAVIER RAMÍREZ GONZÁLEZ¹

javier.ramirez@cicese.edu.mx

¹*Departamento de Ciencias de la Computación,
Centro de Investigación Científica y de Educación Superior de Ensenada,
Baja California*

Resumen. El reconocimiento automático de movimientos de la mano es un problema en visión por computadora con aplicaciones en interfaces humano-computadora como traducción en lenguas de señas. Este trabajo aborda el problema mediante Modelos Ocultos de Markov (HMM) con emisiones Gaussianas, utilizando un conjunto de datos de 490 videos capturados por 5 participantes. Los movimientos se dividen en dos grupos, movimientos de contorno que describen la trayectoria global de la mano, y movimientos locales que corresponden a movimientos finos de muñeca y antebrazo. Las características se extraen a sobre puntos de referencia de la mano, modelando la dinámica temporal de cada gesto. La evaluación mediante validación cruzada Leave-One-Participant-Out alcanza 34.1% de exactitud para el grupo de contorno y 69.3% para el local.

Palabras clave: Reconocimiento de gestos, Modelos Ocultos de Markov, MediaPipe, Clasificación de series temporales, LOOCV

1 INTRODUCCIÓN

El reconocimiento de movimientos de la mano es un problema en visión por computadora [1]. Los movimientos son secuenciales, lo que hace de los Modelos Ocultos de Markov (HMM) una opción natural por su capacidad de modelar dinámica temporal mediante estados ocultos [2]. Un HMM representa un gesto como una secuencia de pasos no observables, cada uno con características observables de la mano. Existen modelos más complejos como redes neuronales o transformers, pero los HMM son interpretables así como eficientes en , lo que los hace mucho más adecuados para ciertas aplicaciones. Esto es deseable en lenguas de señas, donde la explicabilidad es importante para validar el sistema con expertos lingüistas.

2 TRABAJO RELACIONADO

Mitra y Acharya [1] presentan una revisión del reconocimiento de gestos con énfasis en gestos manuales y expresiones faciales. Los autores clasifican los métodos en enfoques basados en modelos (HMM, máquinas de estados finitos) y enfoques basados en apariencia (flujo óptico, color de piel, modelos conexionistas). Se identifican los HMM como modelos adecuados para gestos dinámicos por su capacidad de modelar secuencias de longitud variable

mediante estados ocultos que capturan la evolución temporal del movimiento. También existen desafíos como la variabilidad inter-persona, el desbalanceo de clases y la necesidad de características robustas a cambios de iluminación y oclusión.

3 METODOLOGÍA

3.1 Datos y extracción de características

El conjunto de datos contiene 490 videos .MOV, 98 por cada uno de los 5 participantes (P00 a P04). La duración promedio va de 19 frames (CAB) a 66 frames (CIRCULO). Por cada frame se obtienen 21 puntos de referencia de la mano mediante MediaPipe HandLandmarker [3], y se normalizan con respecto a la muñeca. Esto da 63 coordenadas por frame. Se utiliza la velocidad entre frames y la posición de la muñeca, para un total de 129 dimensiones por frame. Para el grupo de contorno se normaliza cada secuencia con z-score; para el grupo local se normaliza por fold y se aplica PCA (95% de varianza).

Table 1. Distribución de muestras y longitud promedio.

Grupo	Clase	N	Frames
Contorno	ARCO	160	28
	CIRCULO	60	66
	LINEA	40	28
	SIETE	40	44
	ZIG	40	57
Local	CAB	50	19
	ROTACION-D	50	21
	ROTACION-O	50	21

3.2 Modelo Oculto de Markov

Un HMM se define como $\lambda = (\boldsymbol{\pi}, \mathbf{A}, \mathbf{B})$ con distribución inicial $\boldsymbol{\pi}$, matriz de transición $\mathbf{A}$ y emisiones Gaussianas $b_i(\mathbf{o}) = \mathcal{N}(\mathbf{o}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$ con covarianza diagonal. La probabilidad de una secuencia $\mathbf{O} = \{\mathbf{o}_1, \dots, \mathbf{o}_T\}$ se calcula mediante el algoritmo Forward:

$$P(\mathbf{O}|\lambda) = \sum_{\mathbf{q}} \pi_{q_1} b_{q_1}(\mathbf{o}_1) \prod_{t=2}^T a_{q_{t-1}q_t} b_{q_t}(\mathbf{o}_t) \quad (1)$$

Table 2. Estados ocultos óptimos por clase (grid search).

Clase	N
<i>Contorno</i>	
ARCO	6
CIRCULO	4
LINEA	3
SIETE	3
ZIG	3
<i>Local</i>	
CAB	6
ROTACION-D	5
ROTACION-O	7

El aprendizaje se realiza con el algoritmo Baum-Welch. Se entrena un HMM independiente por clase y la clasificación asigna $\hat{c} = \arg \max_c \log P(\mathbf{O}|\lambda_c)$. El número de estados ocultos N se seleccionó por búsqueda en rejilla (grid search) sobre el conjunto de entrenamiento de cada fold, evaluando $N \in \{3, 4, 5, 6, 7\}$ con validación cruzada estratificada. La Table 2 resume los valores óptimos por clase. Todos los modelos utilizan covarianza diagonal, 1000 iteraciones, 5 inicializaciones con k-means seleccionando el modelo de mayor log-verosimilitud, y semilla pseudoaleatoria fija para reproducibilidad.

3.3 Validación

Se utiliza validación Leave-One-Participant-Out (LOOCV): en cada iteración se entrenan 4 participantes y se prueba con el restante. Las clases de contorno tienen distinto número de muestras (ARCO tiene 160, el resto 40-60), por lo que se balancean dentro de cada fold: se generan secuencias aumentadas (ruido gaussiano, escalado, warping temporal) en las clases minoritarias hasta alcanzar 60 muestras, y se reducen las muestras de ARCO al mismo nivel por sub-muestreo aleatorio. Se reportan exactitud, recall y F1-score promedio macro.

4 RESULTADOS

4.1 Resultados de clasificación

La Table 3 muestra los resultados por clase. La exactitud global es 34.1% para contorno y 69.3% para local. Las Figs. 1 and 2 muestran las matrices de confusión.

Table 3. Resultados por clase.

Clase	Acc.	Rec.	F1
CIRCULO	0.203	0.400	0.270
ARCO	0.684	0.338	0.452
LINEA	0.407	0.600	0.485
SIETE	0.233	0.250	0.241
ZIG	0.098	0.100	0.099
CAB	0.552	0.740	0.632
ROTACION-D	0.907	0.780	0.839
ROTACION-O	0.700	0.560	0.622




Fig. 1. Matriz de confusión para contorno.




Fig. 2. Matriz de confusión para local.

El principal problema es la confusión entre clases de contorno: ARCO se confunde con CIRCULO y LINEA. ZIG es la clase más difícil (F1=0.099), probablemente por su alta variabilidad y pocas muestras. En local, ROTACION-D se distingue bien (F1=0.839), mientras que CAB y ROTACION-O se confunden entre sí.

5 CONCLUSIONES

Más allá de las limitaciones específicas de este trabajo, los HMM han caído en desuso frente a arquitecturas profundas (LSTM, transformers) por varias razones: (i) los HMM asumen que la observación en cada instante depende solo del estado oculto actual, lo cual ignora correlaciones

de largo alcance en la señal; (ii) las emisiones Gaussianas con covarianza diagonal no capturan relaciones no lineales entre dimensiones; (iii) el número de estados debe definirse a priori y su interpretación no siempre se corresponde con sub-movimientos reales; y (iv) los HMM son difíciles de escalar a conjuntos grandes de datos y clases. Los modelos modernos, si bien requieren más datos, ofrecen representaciones aprendidas de extremo a extremo y mejor rendimiento en métricas de clasificación .

6 REFERENCES

- [1] S. Mitra and T. Acharya, “Gesture Recognition: A Survey,” *IEEE Trans. Syst., Man, Cybern. C*, vol. 37, no. 3, pp. 311–324 (2007).
- [2] L. R. Rabiner, “A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition,” *Proc. IEEE*, vol. 77, no. 2, pp. 257–286 (1989).
- [3] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, et al., “MediaPipe: A Framework for Perceiving and Processing Reality,” in *Proc. Third Workshop on Computer Vision for AR/VR at IEEE CVPR* (2019).